

暨南大学本科实验报告专用纸

课程名称 计算机视觉实验 成绩评定

实验项目名称 基于 MediaPipe Pose 与骨架序列 Transformer 的羽毛球击球动作识别实验

指导教师 赵乘骥 实验项目类型 仿真 实验地点 教 108

学生姓名 李智阳 学号 2023100066 组号 无

学院 国际能源学院 系 专业 自动化

实验时间 2026 年 6 月 12 日下午~6 月 12 日下午 温度 30°C 湿度 96%

一、实验目的

本实验以 Kaggle 羽毛球击球动作视频数据集为对象，完成基于 MediaPipePose 与骨架序列 Transformer 的视频动作识别流程。实验不直接将原始视频像素输入大型视频模型，而是先将每段视频转换为人体骨架时间序列，再利用轻量级 TransformerEncoder 进行动作分类。

通过本实验，可以理解视频动作识别任务如何转化为序列建模任务，并掌握视频读取、骨架关键点提取、序列重采样、模型训练、测试评估和单视频推理的完整流程。

二、数据集说明

实验使用 badminton_storke_video 数据集。该数据集包含 6 类羽毛球击球动作视频片段，类别覆盖正手与反手击球动作。程序递归遍历数据集根目录后共识别到 836 个视频样本，并按照 test_size=0.2 划分为训练集和测试集。

标签编号	英文类别	中文说明
0	forehanddrive	正手平抽/正手驱动球
1	forehandlift	正手挑球
2	forehandnetshot	正手网前球
3	forehandclear	正手高远球
4	backhanddrive	反手平抽/反手驱动球
5	backhandnetshot	反手网前球

三、数据预处理

预处理阶段主要包括视频读取、骨架提取、归一化、重采样和数据保存。程序读取数据集中的.mp4、.avi、.mov、.mkv等视频文件，并根据视频所在文件夹名称推断动作标签。

MediaPipePose 每帧输出 33 个关键点，每个关键点包含 x、y、z 和 visibility 四个数值，因此每帧骨架特征维度为 $33 \times 4 = 132$ 。为减少不同人体位置和尺度差异的影响，实验以左右髋部中心作为坐标原点，并以肩宽作为尺度因子进行归一化。对于未检测到人体的帧，程序采用上一帧有效骨架进行简单填补；对于不同长度的视频，则通过线性插值重采样为固定长度 30 帧。

预处理完成后，训练集输入 X_{train} 的形状为 $[668, 30, 132]$ ，测试集输入 X_{test} 的形状为 $[168, 30, 132]$ ，其中 30 表示每段视频统一后的帧数，132 表示每帧骨架特征维度。

四、模型结构设计

实验采用轻量级 SkeletonTransformer。输入为形状 $[B, 30, 132]$ 的骨架序列，其中 B 为 batchsize。模型首先通过线性映射层将 132 维输入映射到 $d_{model}=128$ 维，然后加入可学习的位置编码，使模型能够感知时间顺序。

随后，模型使用 2 层 TransformerEncoder 对骨架序列进行时序特征建模，并通过 CLToken 汇聚整段动作的全局信息。最后将 CLToken 的输出特征送入 MLP 分类器，得到 6 类羽毛球击球动作的 logits。

五、训练设置

训练阶段使用 CrossEntropyLoss 作为多类别分类损失函数，优化器为 Adam，学习率为 $1e-3$ ，权重衰减为 $1e-4$ ，batchsize 设置为 16。实验初次训练 30 轮时测试准确率约为 50.60%；随后将训练轮数增加至 50，并加入轻微骨架噪声增强，最终测试准确率提升至 60.12%。

数据增强只对骨架坐标加入较小高斯噪声，不扰动 visibility。这样可以模拟姿态估计中的轻微误差，提高模型对骨架提取误差的鲁棒性。训练过程中，程序在每个 epoch 记录 train_loss、train_acc、test_loss 和 test_acc，并保存到 processed/train_history.csv。

六、实验结果与分析

6.1 预处理结果

预处理程序共读取并处理 836 个视频样本，划分后训练集包含 668 个样本，测试集包含 168 个样本。每个样本的输入形状为 $[30, 132]$ ，符合骨架时间序列分类任务的输入要求。

6.2 训练曲线

根据 train_history.csv 绘制训练集和测试集的准确率曲线与损失曲线，结果如下。




图 1 训练集与测试集准确率曲线




图 2 训练集与测试集损失曲线

由图 1 可见，随着训练轮数增加，训练集准确率持续上升，测试集准确率整体也呈上升趋势，最终约为 60.12%。由图 2 可见，训练损失持续下降，而测试损失在后期出现波动并有所升高，说明模型在训练后期存在一定过拟合现象。

6.3 测试集分类结果

在 50 轮训练并加入数据增强后，模型在测试集上的最终准确率为 60.12%。分类报告中，macroavg 的 precision、recall 和 f1-score 分别为 0.5914、0.5842 和 0.5852；

weightedavg 的 precision、recall 和 f1-score 分别为 0.6014、0.6012 和 0.5987。该结果说明模型已经能够学习到部分击球动作的骨架时序差异，但仍存在一定类别混淆。

```
===== Final Test Result =====
Best test accuracy: 0.6012

Confusion Matrix:
[[16  2  1  5  4  4]
 [ 1 25  3  3  2  1]
 [ 4  1 12  0  1  3]
 [ 2  4  0 12  3  3]
 [ 2  3  0  4 10  3]
 [ 2  1  2  3  0 26]]

Classification Report:
              precision    recall  f1-score   support

 forehand drive      0.5926      0.5000      0.5424         32
 forehand lift       0.6944      0.7143      0.7042         35
 forehand net shot   0.6657      0.5714      0.6154         21
 forehand clear      0.4444      0.5000      0.4706         24
 backhand drive      0.5000      0.4545      0.4762         22
 backhand net shot   0.6500      0.7647      0.7027         34

   accuracy          0.5914      0.5842      0.5852        168
  macro avg          0.5914      0.5842      0.5852        168
 weighted avg         0.6014      0.6012      0.5987        168
```

图3：工作区输出

项目	结果
总视频样本数	836
训练集/测试集	668/168
单样本输入形状	[30, 132]
最终测试准确率	60.12%
单视频推理置信度	0.8631

6.4 单视频推理结果

为了验证模型的推理流程，选取 archive/forehand_net_shot/071.mp4 作为单样本输入。该视频所在文件夹标签为 forehandnetshot，模型输出的预测类别同样为 forehandnetshot，预测置信度为 0.8631，说明模型对该样本判断较为稳定。

项目	结果
测试视频	./archive/forehand_net_shot/071.mp4
真实类别	forehandnetshot
预测类别	forehandnetshot
置信度	0.8631
是否预测正确	是

```
(.venv-basic) lzy@lzy:~/cv-course/build/实验11$ python badminton_skeleton_transformer.py infer \
--video "./archive/forehand_net_shot/071.mp4" \
--ckpt "./processed/best_model.pt"
Predicted class: forehand net shot
Confidence: 0.8631

Class probabilities:
0 | forehand drive      : 0.0425
1 | forehand lift       : 0.0008
2 | forehand net shot   : 0.8631
3 | forehand clear      : 0.0070
4 | backhand drive      : 0.0456
5 | backhand net shot   : 0.0409
(.venv-basic) lzy@lzy:~/cv-course/build/实验11$
```

图 4 单视频样本推理结果

七、问题分析与改进方向

从训练曲线可以看出，模型在训练集上持续收敛，但测试损失后期波动并升高，说明模型存在一定过拟合。产生该现象的原因可能包括：数据集规模相对有限；不同击球动作在骨架序列上的差异较小；正手网前球与反手网前球等动作具有相似的挥拍和移动模式，容易被模型混淆。

后续可以从以下方面改进：第一，加入更丰富的数据增强，如时间裁剪、时间缩放、水平翻转和关键点随机遮挡；第二，引入早停策略，在测试集性能不再提升时停止训练；第三，适当增大 dropout 或降低模型复杂度以缓解过拟合。

八、实验结论

本实验完成了从羽毛球击球视频到骨架时间序列分类的完整流程。实验首先使用 MediaPipePose 将视频帧转换为人体的 33 个关键点的骨架特征，再将不同长度的视频统一重采样为 [30, 132] 的固定长度序列，最后使用轻量级 SkeletonTransformer 进行 6 类动作分类。

实验结果表明，经过 50 轮训练并加入轻微骨架噪声增强后，模型在测试集上的准确率达到 60.12%，并在单视频推理样本中正确识别出 forehandnetshot，置信度为 0.8631。该方法计算量较低、特征具有较强可解释性，但在动作相似类别上仍存在混淆，需要通过数据增强、模型正则化和特征改进提升泛化能力。