

暨南大学本科实验报告专用纸

课程名称 计算机视觉实验 成绩评定

实验项目名称 传统机器学习方法在手写数字图像分类中的应用

指导教师 赵乘骥 实验项目类型 仿真 实验地点 教 108

学生姓名 李智阳 学号 2023100066 组号 无

学院 国际能源学院 系 专业 自动化

实验时间 2026 年 5 月 8 日下午~5 月 8 日下午 温度 24°C 湿度 73%

一、 实验目的

- 1.理解图像如何转换为机器学习模型可以处理的特征向量。
- 2.理清训练集和测试集的基本概念。
- 3.熟悉常见传统机器学习分类方法的基本使用。
- 4.区分不同分类器在同一图像分类任务中的表现差异。
- 5.学会使用准确率、混淆矩阵和错误样本分析评价分类结果。
- 6.完成本次课程实验报告。

二、 数据集说明

1. 数据集名称: sklearn.datasets 内置手写数字数据集 (Digits Dataset)。
2. 图像大小: 单张图像为 8×8 像素的灰度图像, 像素值范围为 0~16 (灰度等级)。
3. 样本数量: 共 1797 张图像, 用于实验时按 75%:25% 划分为训练集与测试集。
4. 类别数量: 10 个类别, 对应数字 0~9。
5. 图像表示为特征向量: 将 8×8 的二维图像矩阵按行优先展平, 转换为 64 维的一维向量, 作为机器学习模型的输入特征。即: 8×8 图像 $\rightarrow$ flatten() $\rightarrow$ 64 维特征向量, 向量中每个元素对应一个像素的灰度值。

三、 实验方法

本次实验选用了 KNN、朴素贝叶斯、逻辑回归、SVM、决策树、随机森林六种经典传统机器学习方法, 覆盖了基于距离、概率、线性模型、核方法、单模型与集成模型的不同类型。通过对比它们在同一手写数字数据集上的表现, 能够直观理解不同算法的适用场景与性能差异, 下面对这六种方法进行简要说明。

1. KNN 基于距离度量的非参数方法，通过最近邻样本投票确定类别。
2. Naive Bayes 基于贝叶斯定理与特征独立性假设，通过概率模型完成分类。
3. Logistic Regression 线性模型，通过学习特征与类别的线性关系，输出样本属于各类别的概率。
4. SVM 在高维空间中寻找具有最大间隔的分类超平面，实现样本的最优划分。
5. Decision Tree 基于特征阈值递归划分样本，形成树形决策路径，完成分类。
6. Random Forest 集成学习方法，通过多棵决策树的独立预测投票，降低单棵树的过拟合风险。

四、 实验结果

任务一：

```
===== 任务1: 数据准备 =====  
图像总数: 1797  
单张图像大小: (8, 8)  
所有标签: [0 1 2 3 4 5 6 7 8 9]  
样本图像已保存为 task1_samples.png
```

任务二：

```
===== 任务1: 数据准备 =====  
图像总数: 1797  
单张图像大小: (8, 8)  
所有标签: [0 1 2 3 4 5 6 7 8 9]  
样本图像已保存为 task1_samples.png
```

说明：训练集用于模型训练。模型通过学习训练集中的样本特征与标签之间的映射关系，调整自身参数，从而构建起分类或预测能力。本实验中约 75% 的数据作为训练集，用于让模型学习手写数字的像素特征与数字类别的对应关系。

测试集用于模型评估。在模型训练完成后，使用从未见过的测试集数据来评估模型的泛化能力，检验其在新数据上的分类准确率。本实验中约 25% 的数据作为测试集，用于客观衡量各模型的真实性能，避免过拟合带来的评价偏差。

任务三：

```
===== 任务3: 特征表示 =====
原始图像尺寸: 8x8 二维矩阵
展平后特征向量: 64维一维向量
原图像 shape: (8, 8)
特征向量 shape: (64,)

像素特征优点: 简单直接、无需手工设计
像素特征缺点: 对位移/旋转敏感、无空间结构信息
```

结果分析：

- ①8×8 图像到 64 维向量的转换方法：将 8×8 二维图像矩阵按行优先顺序展平，把所有像素值拼接成一维数组，即可得到 64 维特征向量。在代码中可通过 `image.flatten()`实现。
- ②传统机器学习方法需要特征转换的原因：传统机器学习模型的输入接口为一维向量，不直接支持二维矩阵数据，因此需要通过展平操作将图像转换为模型可接受的格式，以便进行距离计算、线性拟合等操作。
- ③原始像素作为特征的优缺点
优点：无需复杂特征工程，直接保留图像全部原始信息，实现简单。
局限：丢失了像素间的空间关系，对平移、旋转等变化敏感，高维像素特征易引发过拟合和计算效率问题。

任务四和任务五：

```
===== 任务4: 模型训练与预测 =====
KNN                准确率: 0.9933
Naive Bayes        准确率: 0.8556
Logistic Regression 准确率: 0.9733
SVM                准确率: 0.9867
Decision Tree      准确率: 0.8711
Random Forest      准确率: 0.9733
```

制成表格：

模型	测试准确率
KNN	0.9933
Naive Bayes	0.8556
Logistic Regression	0.9733
SVM	0.9867

模型	测试准确率
Decision Tree	0.8711
Random Forest	0.9733

分析：从表中可以看出，不同模型在手写数字分类任务中的表现存在明显差异。整体准确率由高到低排序为：KNN > SVM > Logistic Regression / Random Forest > Decision Tree > Naive Bayes。

KNN 模型表现最优，测试准确率达到 0.9933。这是因为手写数字的像素特征在空间中具有较高的类内相似性，基于距离度量的 KNN 算法可以通过“最近邻投票”的方式高效地完成分类，在本实验的低噪声、低维数据上展现出了极强的性能。

SVM 模型紧随其后，准确率为 0.9867。它通过核函数将数据映射到高维空间，并寻找具有最大间隔的分类超平面，能够有效捕捉不同数字之间的决策边界，泛化能力优秀。


逻辑回归与随机森林的准确率均为 0.9733，表现稳定。逻辑回归作为线性模型，在像素特征上学习到了有效的线性决策边界；而随机森林通过集成多棵决策树，显著降低了单棵树的过拟合风险，提升了模型的鲁棒性。

相比之下，单棵决策树和朴素贝叶斯的表现较弱。决策树由于容易过拟合训练数据，泛化能力较差，准确率仅为 0.8711；而朴素贝叶斯基于特征独立性假设，这与图像像素之间的空间相关性不符，因此在本任务中建模能力有限，准确率仅为 0.8556。


综上所述，基于距离度量和核方法的模型（KNN、SVM）在像素特征上表现出明显优势，是本任务的最优选择；而集成学习（随机森林）也有效提升了模型的稳定性和准确率。

任务六：

混淆矩阵：



错误样本：



误判数字分析：模型的误分类主要集中在少数几组形态相似的数字上，如：真实为 3 的样本被误判为 8；真实为 5 的样本被误判为 6；真实为 7 的样本被误判为 9；真实为 8 的样本被误判为 9；真实为 9 的样本被误判为 5 或 7。

原因分析：

- ①低分辨率导致细节丢失，8×8 的图像无法保留手写数字的细微特征，模型只能依赖整体轮廓进行判断，容易被相似的局部像素模式误导。
- ②手写形态的多样性，部分样本的手写风格不标准，笔画变形、倾斜或不完整，导致与其他数字的像素特征产生重叠。
- ③原始像素特征的局限性，模型仅基于像素灰度值学习特征，缺乏对数字拓扑结构、空间关系的理解，对相似形态的区分能力有限。

五、 实验总结

1. 传统机器学习处理图像的基本流程

本次实验我基本掌握了传统机器学习处理图像任务的通用流程，包括：

- ①数据加载与预处理：加载数据集，将二维图像展平为一维特征向量，为模型输入做准备。
- ②数据集划分：按比例将数据划分为训练集和测试集，分别用于模型训练与性能评估。
- ③模型训练：使用多种传统机器学习算法在训练集上拟合数据，学习特征与标签的映射关系。
- ④模型评估：在测试集上计算准确率、绘制混淆矩阵，并分析错误样本，全面评价模型性能。

2. 不同分类器的优缺点

模型	优点	缺点
KNN	实现简单，无需训练，对低维、类内相似性高的数据表现极佳	对高维数据计算效率低，易受噪声样本影响
SVM	泛化能力强，在小样本、高维数据上表现优秀，抗过拟合能力好	训练速度慢，对大规模数据计算成本高

模型	优点	缺点
逻辑回归	训练速度快，模型可解释性强，适合线性可分数据	对非线性边界数据拟合能力有限
随机森林	抗过拟合能力强，稳定性高，能有效捕捉非线性关系	模型复杂度较高，训练时间比单棵决策树长
决策树	模型结构直观，可解释性强，训练速度快	易过拟合，泛化能力差，对数据微小变化敏感
朴素贝叶斯	训练和预测速度快，实现简单	特征独立性假设与图像数据不符，建模能力有限

3. 使用原始像素作为特征的局限

实验中直接将 8×8 图像的像素值展平为 64 维向量作为特征，暴露出以下局限：

- ①丢失空间信息，展平操作破坏了像素间的二维空间关系，模型无法理解图像的结构与拓扑特征。
- ②对变化敏感，图像的微小平移、旋转或缩放会导致像素向量发生显著变化，模型鲁棒性差。
- ③特征区分度不足，低分辨率下，形态相似的数字（如 5 与 6、7 与 9）像素模式差异极小，模型难以区分。
- ④维度诅咒风险，对于高分辨率图像，像素特征维度极高，易导致模型训练困难、过拟合和计算效率低下。

六、 思考题

1. 为什么传统机器学习方法需要先把图像转换为特征向量？

答：传统机器学习模型的设计通常是为了处理一维特征向量数据，无法直接接收二维矩阵格式的图像。将图像展平为向量，是为了让每个像素值成为模型可以直接计算的独立特征，从而进行距离度量、概率估计或线性拟合，这是连接图像数据与模型算法的必要步骤。

3. KNN、SVM、决策树和随机森林的分类思想有什么不同？

- 答：①KNN 基于“物以类聚”的思想，通过寻找与待分类样本距离最近的 k 个训练样本，以多数投票的方式决定其类别。
- ②SVM 寻找一个具有最大间隔的分类超平面，将不同类别的样本分隔开，以最大化两类样本之间的距离来保证模型的泛化能力。
- ③决策树通过一系列基于特征阈值的“是/否”问题，递归地将样本划分到不同分支，最终得到一个树形的决策路径。
- ④随机森林通过训练多棵独立的决策树，并对所有树的预测结果进行投票，以降低单棵树的

过拟合风险，提升模型稳定性。

3. 为什么单棵决策树容易过拟合？

答：单棵决策树在训练时会不断划分节点，直到将训练数据完全分开。它会学习到训练数据中的所有细节和噪声，甚至把随机误差也当作规律来拟合，导致模型在训练集上表现极好，但在新的测试数据上泛化能力很差。

4. 为什么随机森林通常比单棵决策树更稳定？

答：随机森林通过训练多棵决策树，并在训练过程中引入样本和特征的随机选择，使每棵树的学习过程相互独立。最终的预测结果由多棵树投票决定，这大大降低了模型对训练数据中局部噪声和异常值的敏感度，从而提升了整体稳定性和泛化能力。

5. 如果图像发生平移、旋转或缩放，直接使用原始像素作为特征会有什么问题？

答：直接使用原始像素作为特征，模型对图像的空间变化不具备鲁棒性。平移、旋转或缩放会导致图像中每个像素的位置发生变化，即使是同一数字，其像素向量也会变得完全不同，导致模型无法识别出这是同一类物体，从而大幅降低分类准确率。