

暨南大学本科实验报告专用纸

课程名称 计算机视觉实验 成绩评定

实验项目名称 PyTorch 入门与图像分类

指导教师 赵乘骥 实验项目类型 仿真 实验地点 教 108

学生姓名 李智阳 学号 2023100066 组号 无

学院 国际能源学院 系 专业 自动化

实验时间 2026 年 5 月 15 日下午~5 月 15 日下午 温度 25°C 湿度 96%

一、实验目的

- 掌握卷积神经网络（CNN）的基本原理，理解卷积层、池化层、全连接层的作用，完成图像分类全流程实现。
- 熟悉 MNIST 手写数字数据集，掌握数据集加载、预处理、划分训练集、验证集、测试集的方法。
- 搭建 CNN 模型，完成模型训练、验证、测试，通过 loss 与 accuracy 曲线分析模型收敛与过拟合情况。
- 实现数据可视化，直观展示训练样本与测试集预测效果。
- 引入 Dropout 正则化，抑制模型过拟合，提升泛化能力。
- 对比 Adam、SGD 两种优化器对模型训练速度、准确率的影响。
- 对比 MNIST 与 CIFAR-10 数据集，探究图像复杂度对分类任务性能的影响。

二、数据集说明

1. MNIST 数据集：单通道 28×28 灰度手写数字图像，共 10 个类别（0-9）；训练集 60000 张，测试集 10000 张；本实验将训练集按 8:2 划分为训练子集与验证子集。

2. CIFAR-10 数据集：三通道 32×32 彩色自然图像，共 10 个类别；用于进阶任务，对比复杂图像的分类难度。

3. 预处理：MNIST 归一化均值 0.1307、方差 0.3081；CIFAR-10 归一化均值 (0.4914, 0.4822, 0.4465)、方差 (0.2470, 0.2435, 0.2616)。

三、CNN 模型结构

3.1 结构如下：

- 1. 第一层卷积：输入通道 1，输出通道 16，卷积核 3×3，填充 1
- 2. ReLU 激活函数
- 3. 最大池化：池化核 2×2
- 4. 第二层卷积：输入通道 16，输出通道 32，卷积核 3×3，填充 1
- 5. ReLU 激活函数
- 6. 最大池化：池化核 2×2
- 7. 展平层
- 8. 全连接层 1：32×7×7 → 128
- 9. ReLU 激活函数
- 10. 全连接层 2：128 → 10（输出分类结果）

3.2 各层作用

- ①卷积层：提取图像边缘、角点、纹理等特征
- ②ReLU 激活函数：引入非线性，增强模型表达能力
- ③最大池化层：下采样，降低维度，保留关键特征
- ④展平层：将二维特征图转为一维向量
- ⑤全连接层：完成最终 10 分类任务

四、 训练参数设置

参数	取值	说明
批次大小	64	每次送入模型的样本数量
学习率 lr	0.001	Adam、SGD 统一使用该学习率
训练轮数 epochs	10	共训练 10 轮
优化器 1	Adam	自适应学习率优化器，无动量
优化器 2	SGD	带动量 SGD，momentum=0.9
损失函数	CrossEntropyLoss	多分类任务标准损失函数

五、 训练与验证结果

训练与验证 loss 和 accuracy 结果


基础任务 CNN 训练与验证结果				
Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	0.1963	0.9411	0.0710	0.9782

2	0.0562	0.9826	0.0614	0.9816
3	0.0393	0.9878	0.0442	0.9868
4	0.0303	0.9902	0.0455	0.9864
5	0.0214	0.9930	0.0389	0.9893
6	0.0175	0.9945	0.0496	0.9864
7	0.0153	0.9949	0.0388	0.9898
8	0.0121	0.9956	0.0390	0.9900
9	0.0099	0.9969	0.0455	0.9887
10	0.0083	0.9971	0.0489	0.9891

测试集 loss 与 accuracy:


Test Loss: 0.0396 Acc: 0.9890

六、 loss 曲线与 accuracy 曲线



(基础任务 loss 曲线与 accuracy 曲线)

七、 基础实验预测结果示例



八、 进阶实验部分

进阶任务 1:

在基础 CNN 模型基础上，主要进行两处修改：

- ①在卷积层、全连接层后加入 Dropout 层（卷积层 $p=0.2$ ，全连接层 $p=0.5$ ）；
- ②未增加卷积层数，保持 2 层卷积结构，仅增加正则化模块。

2. 性能对比

- ①基础模型（无 Dropout）：测试准确率 98.90%，训练后期存在轻微过拟合；
- ②修改后模型（加入 Dropout）：测试准确率 99.08%，训练-验证准确率差距明显缩小。

3. 结果与原因分析

- ①测试准确率小幅提升，模型泛化能力增强；
- ②Dropout 通过随机丢弃部分神经元，避免模型过度记忆训练集噪声，有效抑制了过拟合；
- ③本任务为简单手写数字分类，基础网络已足够提取特征，因此准确率提升幅度较小。

进阶任务 2:

Optimizer	Learning Rate	Test Accuracy
SGD	0.001	0.9831
Adam	0.001	0.9908

结果分析:

- ①收敛速度：Adam 优化器收敛更快，前期训练准确率提升幅度大；SGD 收敛平缓，前期精度较低，迭代过程更慢。
- ②最终性能：相同学习率下，Adam 测试准确率更高，为 99.08%，优于 SGD 的 98.31%。
- ③原因：Adam 具备自适应学习率机制，可根据参数梯度动态调整更新步长；SGD 使用固定学习率，更新方式单一，收敛速度较慢。

进阶任务 3:

数据集	图像类型	类别数	测试准确率	难度
MNIST	灰度手写数字	10	0.9908	简单
CIFAR-10	彩色自然图像	10	0.6753	复杂

为什么 CIFAR-10 比 MNIST 更难？

- ①图像通道与信息维度：MNIST 是单通道灰度图，仅包含明暗信息；CIFAR-10 为三通道彩色

图像，特征维度更高，需要学习色彩、纹理、形状等更多信息。

②背景干扰差异：MNIST 背景纯白、无多余干扰，目标（手写数字）突出；CIFAR-10 包含复杂自然背景，物体存在遮挡、光影变化，噪声更多。

③图像细节复杂度：手写数字结构简单、轮廓规整；自然物体形态多样、细节复杂，同类物体差异大，不同类别容易混淆。

④模型适配难度：同等轻量 CNN 模型，对简单灰度特征提取效果好；彩色复杂图像需要更深、更复杂的网络才能充分提取特征，因此准确率显著更低。

附：进阶任务部分的 loss 与 accuracy 与测试集

MNIST（带 Dropout，Adam 优化器）				
Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	0.3322	0.8951	0.0873	0.9725
2	0.1330	0.9607	0.0588	0.9819
3	0.1047	0.9694	0.0540	0.9828
4	0.0889	0.9734	0.0502	0.9851
5	0.0790	0.9762	0.0415	0.9872
6	0.0750	0.9771	0.0410	0.9873
7	0.0661	0.9803	0.0384	0.9877
8	0.0610	0.9815	0.0427	0.9874
9	0.0579	0.9816	0.0370	0.9881
10	0.0531	0.9839	0.0384	0.9892

MNIST（带 Dropout，SGD 优化器）				
Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	1.0215	0.6724	0.3204	0.9101
2	0.3978	0.8776	0.1889	0.9459
3	0.2743	0.9184	0.1416	0.9583
4	0.2207	0.9331	0.1149	0.9658
5	0.1850	0.9439	0.1016	0.9694
6	0.1647	0.9495	0.0901	0.9728
7	0.1523	0.9538	0.0810	0.9752

8	0.1386	0.9571	0.0757	0.9768
9	0.1305	0.9610	0.0715	0.9777
10	0.1202	0.9637	0.0683	0.9782

CIFAR-10（带 Dropout，Adam 优化器）

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	1.6567	0.3963	1.3712	0.5085
2	1.3814	0.5022	1.2315	0.5540
3	1.2724	0.5433	1.1367	0.5964
4	1.2100	0.5683	1.0893	0.6161
5	1.1544	0.5904	1.0362	0.6368
6	1.1201	0.6052	1.0035	0.6488
7	1.0818	0.6172	0.9748	0.6670
8	1.0541	0.6265	0.9537	0.6716
9	1.0264	0.6334	0.9369	0.6718
10	1.0090	0.6434	0.9172	0.6751

测试集

实验配置	Test Loss	Test Acc
MNIST + Dropout + Adam	0.0276	0.9908
MNIST + Dropout + SGD	0.0516	0.9831
CIFAR-10 + Dropout + Adam	0.9169	0.6753

九、 结果分析与总结

一、基础任务结果分析与总结

本任务采用基础 CNN 模型对 MNIST 手写数字数据集进行分类，网络包含两层卷积、两层池化和两层全连接层，未使用 Dropout 等正则化方法，使用 Adam 优化器训练 10 轮。

实验结果显示，模型测试集准确率达到 98.90%，训练损失由 0.1963 快速下降至 0.0083，验证准确率稳定在 98%~99%，说明基础 CNN 能够高效提取数字图像特征，训练过程收敛迅速、分类性能优异。

训练后期训练准确率略高于验证准确率，出现轻微过拟合，但整体影响较小。可视化结果表明模型对测试样本预测完全正确，进一步验证了模型可靠性。

综上，基础 CNN 结构简单、计算量小，在 MNIST 数据集上可实现高精度分类，完全满足实验要求。

二、进阶任务结果分析与总结

1. 进阶任务 1:

在基础 CNN 中加入 Dropout 层，卷积层随机失活 20%神经元，全连接层随机失活 50%神经元。

结果显示，模型测试准确率提升至 99.08%，训练与验证准确率差距明显缩小，过拟合得到有效抑制，模型泛化能力增强。

实验证明，Dropout 通过随机破坏神经元连接，避免模型过度依赖局部特征，是简单有效的正则化方法。

2. 进阶任务 2:

固定网络结构与学习率，分别使用 Adam 和 SGD 训练。

结果表明，Adam 优化器收敛更快、精度更高，测试准确率达到 99.08%；SGD 收敛平缓、前期精度低，最终测试准确率为 98.31%。

原因在于 Adam 具备自适应学习率调整能力，能动态更新参数，适合快速高效训练；SGD 采用固定学习率，收敛较慢但稳定性较强。

3. 进阶任务 3:

使用相同网络在 MNIST 和 CIFAR-10 上训练。

MNIST 测试准确率高达 99.08%，而 CIFAR-10 仅为 67.53%。原因是 MNIST 为单通道灰度图、目标清晰、背景干净；CIFAR-10 为三通道彩色自然图像，背景复杂、物体形态多样、特征提取难度大。

实验说明数据集复杂度直接决定分类任务难度与模型最终性能。

三、整体总结

- ①基础 CNN 在简单图像分类任务中表现极强，可快速实现高精度分类；
- ②Dropout 能有效抑制过拟合，提升模型泛化能力；
- ③Adam 优化器收敛速度与效果显著优于 SGD，更适合本实验；
- ④数据集复杂度对模型性能影响巨大，复杂图像需要更强的网络结构；
- ⑤深度学习模型的结构、正则化、优化器、数据集共同决定最终训练效果。

